导师阶段汇报 / AGENT HARNESS

从真实执行轨迹到可验证的行为策略

AgentFlow 自进化系统
当前机制、实验进展与研究方向

从真实执行轨迹到可验证的行为策略

系统梳理 · 实验审计 · 下一步研究讨论

2026.10.09 · 约 30 分钟

代码快照 f44bbaf4 · 现存实验产物核查

运行

C++ / Python Harness

学习

轨迹 → 经验 → 策略

验证

同题对照 / 真实应用

证据： harness_agent_poc_evo · README.md

当前结论：工程闭环已形成，研究证据仍需补强

先讲已经能够确认的结论，再展开机制、实验与研究问题。

系统已有闭环

执行 → 轨迹 → 评测 → 记忆 → 策略 → 后续执行

开发对照已有增益

322 → 338 / 500；无效 loop 下降 46.32%

既定目标尚未达标

严格通过与质量相对提升 4.968944% < 5%

下一步先补证据

独立留出、应用消融、稳定性与完整成本

核心讨论：怎样把“可运行的自进化”推进为“可证明的自进化收益”？

30 分钟汇报路线

主讲 30 页，答疑附录补充源码定位、状态语义与复现边界。

系统底座

仓库地图、请求链路、在线与后台职责

自进化机制

打点、评测、记忆、 L1–L3 、 GEPA 与准入

实验审计

500 题成绩、搜索失败、成本与选择偏差

研究讨论

可回答的问题、对照设计、交付顺序

主线始终围绕：系统做了什么、证据支持什么、下一步验证什么。

仓库由执行底座、 Agent Harness 与演化组件组成

C++ 管理执行与状态； Python 驱动模型与工具；独立组件负责学习和策略。

模块	主要位置	职责
执行与通信	src/agent 、 workflow 、 runtime 、 daemon	身份、调度、并发、 DataBus 、 RPC
Agent Harness	packages/agentflow-runtime	LLM 决策、技能、工具与循环
演化组件	tools/trajectory_evolution	轨迹、评测、记忆、策略与 GEPA
接口与宿主	frontend/bridge ； examples/agent	业务 API 、工具环境、评测接线
实验与验收	benchmark ； experiments ； tests	对照协议、来源校验、分层验证

理解源码先沿一轮真实任务走，再沿同一条轨迹走进后台学习。

证据： CMakeLists.txt:355,429 · CMakeLists.txt:4,155,217,240

一次请求怎样跨语言执行并返回结果

下面是受测 v1 Harness 的代表路径； Bridge 之外也有 SDK 与实验入口。

01

请求入口

Bridge / RPC

稳定用户与会话身份

02

任务调度

Session / Task

Scheduler / Worker

03

模型与技能

Python Coordinator

Skill → LLM / Tool

04

批次与结果

DataBus

exec key / ALL join

05

对外返回

ResponsePoller

Bridge / SessionLog

分支结果、模型观察与最终交付共同构成轨迹；单个 success 字段不足以判断任务成功。

执行控制、模型决策和任务验收各有职责。

证据： chat_rest.py:471 · rpc_handler.cpp:418,646

自进化是在线执行与后台学习之间的反馈环

一次 run 使用固定策略；新经验与新版本影响后续 run 。

在线：当前任务

- **冻结策略** — 版本 / 授权
- **执行与查询** — L1 / L2 / L3
- **应用回执** — 真实输入 / 动作
- **任务收尾** — 关闭 / 持久化

后台：后续学习

- **轨迹校验** — Episode / 缺口
- **评测与反思** — 质量 / loop
- **经验与候选** — 审核 / 编译
- **验收与交付** — GEPA / 新版本

反馈：后台批准并交付的新版本 → 后续 run 加载；运行中版本保持固定。

进化对象是行为策略及经验，当前链路不更新模型权重。

证据： local_runtime.cpp:292,340,368 · 01-overview.md

L0–L4： 收集事实、改变行为、搜索新策略

运行授权上限是 L1–L3； L4 用来描述后台优化能力。

L0	**采集与原始基线**	记录任务 / 模型 / 动作 / loop ，不施加演化增强
L1	**经验输入增强**	检索符合身份、作用域与观察条件的批准经验
L2	**动作与编排控制**	参数完整性检查、重试限制、拒绝规则、技能依赖
L3	**循环控制**	continue / replan / stop； 遵守分支及待执行动作条件
L4	**后台候选搜索**	反思变异、多父重组、 Frontier 、验证与准入

代码存在 → 配置开启 → 实际应用 → 同题收益 → 独立留出，逐层核验。

证据： policy_runtime.cpp:112-113 · trajectory_trace.proto:11-18

统一边界协议把执行事实与应用回执关联起来

evolution.boundary.v1 覆盖任务、模型、动作、调度与循环边界。

身份与分支

agent / user / conversation / run ； point 与 parent

边界事实

模型请求、动作输入、工具观察、 loop 决策

因果与幂等

request_id 、 caused_by 、 exec_skill_key 关联事实

真实应用

before 建议 → 实际执行 → advice.applied 核验

打点提供观察与可追溯性；建议产生次数不能当实际应用次数。

轨迹先经过完整性校验，再进入评测与学习

错误轨迹、缺失收尾与采集降级需要显式记录，不能补成健康数据。

01
边界事件
任务 / 模型
工具 / loop

02
规范轨迹
统一结构
保留输入观察

03
完整性校验
身份与引用
缺口 / 隔离

04
评测诊断
质量 / strict
无效 loop

05
学习候选
经验与控制
绑定证据来源

候选必须保留证据、触发条件和适用范围，经过审核后才能进入运行策略。

可学习事实的完整性是策略质量的前提。

评测同时衡量任务成功、有效质量与无效 loop

AppWorld 单目标样本的正式 Q 为 0 / 1；官方部分检查比例另作辅助。

严格通过

原生 verdict=passed；确定性检查与模型验收

有效质量 Q

普通目标完成度；检查失败 / 关键违规影响有效分

平均无效 loop

完整评审中的无效迭代总数 ÷ 有效评审题数

资源与覆盖

时延、 token 、调用和额外尝试分别报覆盖

“质量更高”“轮数更少”“官方任务完成”需要明确各自定义。

记忆是带来源与资格的经验库，不是自由追加文本

私有经验与公共经验分层管理；批准状态、作用域和版本决定可应用资格。

01

真实证据

任务失败与恢复
可追溯来源

02

候选经验

内容 / scope
条件 / 支持

03

审核与管理

合并 / 冲突
反证 / 资格

04

分层记忆

用户私有
受控公共

05

运行资格

已批准且匹配
才能编译应用

入库、批准、发布、加载、应用、收益是不同状态。

证据： 12-reflection-and-candidates.md • 13-private-memory.md

快照冻结内容；检索用当前观察筛选适用经验

当前在线检索以确定性词面匹配为主，不调用模型做语义检索。

冻结的部分

来源版本、经验正文、授权选项和策略身份

变化的部分

当前 task + state 、已执行动作和分支观察

筛选与预算

批准 / scope → 独立词项 → 排序 → 数量与字节

当前限制

否定、任务阶段与长上下文语义不由词面保证

可讨论的改进：后台编译结构化触发器，在线只做轻量且可审计的判定。

证据： 15-policy-snapshots.md:92-136 · local_runtime.cpp:292,368

L1：经验必须进入真实模型请求才算应用

查询命中 → 准备增强输入 → 实际发送 → 复核正文，形成完整证据链。

01

匹配经验

批准 / scope
真实观察条件

02

准备请求

经验进入
messages / tools

03

发送模型

真实 call 使用
prepared request

04

核验回执

注入正文一致
advice.applied

05

比较任务

成功与退步
另行配对验收

最佳 500 题策略 L1=595 次；应用频次是机制证据，不是收益幅度。

L2：在动作与派发位置落实结构化约束

动作约束和技能编排分别记回执，不能只统计生成了多少规则。

工具动作

参数完整性检查、重试限制、动作拒绝

技能编排

依赖条件、派发顺序、 accepted exec key 与 batch 关联

合法性边界

批准来源、 scope 、级别与宿主可落实能力

已有实验

最佳 500 题 L2 动作 =0 、 L2 编排 =0；收益贡献待验证

要证明 L2 有效，需要“可触发任务 + 实际介入 + 同题消融”。

证据： skill_executor.py:83,1359 · coordinator_decide.py:1776,1787

L3： 用真实进展控制 continue / replan / stop

循环控制作用于本分支，并需避免干扰仍在执行的动作。

Continue

无适用停止 / 重规划条件，或仍有在途动作

Replan

符合重规划条件；上下文进入下一真实模型请求

Stop

满足停止条件，保存原因与真实终态

最佳 500 题 L3=4 次；需重点检验误停止、漏触发和任务成功保持。

证据： coordinator_decide.py:1362 · skill_executor.py:834

一条经验怎样走到真实行为：以 API 参数错误为例

示意基于现有产物摘录；本机缺失原轨迹，不能把摘录当完整重验。

01

观察错误

位置参数调用
触发 TypeError

02

提炼经验

核对公开接口
使用正确参数

03

批准与冻结

来源 / scope
content revision

04

运行介入

匹配真实错误
注入与回执

05

任务验收

动作是否修复
任务是否成功

需要同时保存：原始失败 → 经验来源 → 冻结策略 → 实际请求 → 最终验收。

这条链路解释可追溯机制；收益归因仍需同题对照或消融。

证据： INTERMEDIATE_ARTIFACTS.md:22-84 · llm_call.py:89,101

GEPA 在后台反思、变异、重组并比较候选

仓库实现借鉴反思与 Pareto 搜索思想；本仓库收益须用自身实验验证。



每一步都要回答

1. 变更是否合法且有来源?
2. 新控制有没有实际触发?
3. 受影响任务是否真正改善?
4. val 能否支持进入下一阶段?

生成节点、应用变更、通过验证、完成最终对照，不能混为一次“进化成功”。

证据： gepa_search.cpp / agent_evaluation.cpp · GEPA 原论文 arXiv:2507.19457

准入与交付：通过门禁才能称为合格策略

组件支持 train / val / holdout 分工；独立性还取决于实际实验使用方式。

01

训练筛选

合法 / 实际触发
收益与退化检查

02

验证选优

固定 val
候选比较

03

最终对照

同题 / 同裁判
完整覆盖

04

门禁判断

strict 与 Q ⩾5%
loop 下降 ⩾ 15%

05

明确交付

qualified 或
best available

算法结构有 holdout 不等于本次 500 开发对照具有独立留出性质。

证据： gepa_strategy.cpp:53-75 · gepa_search.cpp:7504-7544

AppWorld 协议： 500 题结果属于开发对照

官方环境与评分适配已具备；当前自定义范围不能直接当官方榜单复现。

范围	当前数量与用途	可得结论 / 限制
TRAIN	134： 官方 TRAIN90 + 补充 44	学习来源；原树冻结 132， seed 来源另核
VAL	12	搜索与候选选优
开发验证	32 → 100	固定 500 的前缀子集
500 开发对照	131 normal + 327 challenge + 42 dev	已用于开发反馈，独立性不成立
未来确认评测	待设计并冻结	一次性验收泛化与稳定性

正文写“ 500 题开发对照”，避免把文件名 holdout 当独立性证明。

AppWorld 流程脚本已交付，当前成绩未达目标

已有真实 API 全链路复现说明；本机运行环境与原生报告仍需补齐。

01

训练与学习

真实轨迹
来源审核入库

02

冻结 seed

不可变策略
来源与版本

03

开发门禁

32 → 100
同题复用

04

后台搜索

最多 30 轮
train / val

05

500 与交付

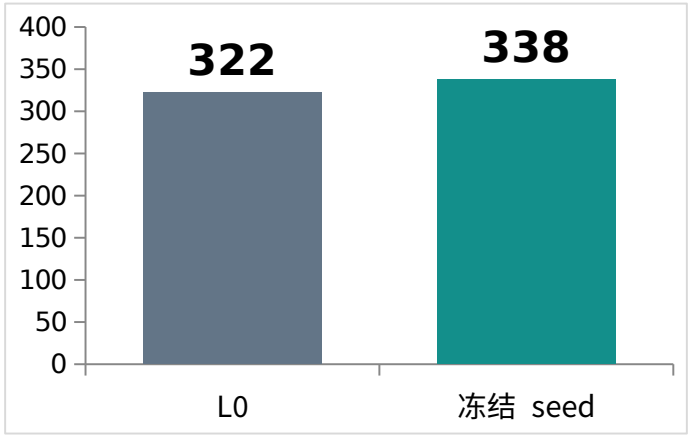
当前 seed 已评分
未达核心门槛

当前交付状态： best_available_not_qualified ； GEPA 未宣称完成。

最佳已评分 seed： 成功增加， loop 明显减少

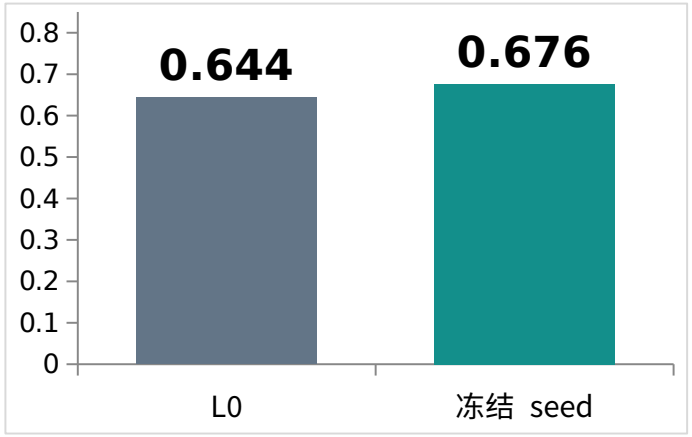
同一 500 题；数值由当前两份逐题摘要复算，原始轨迹与部分原生报告缺失。

正式严格通过 / 500



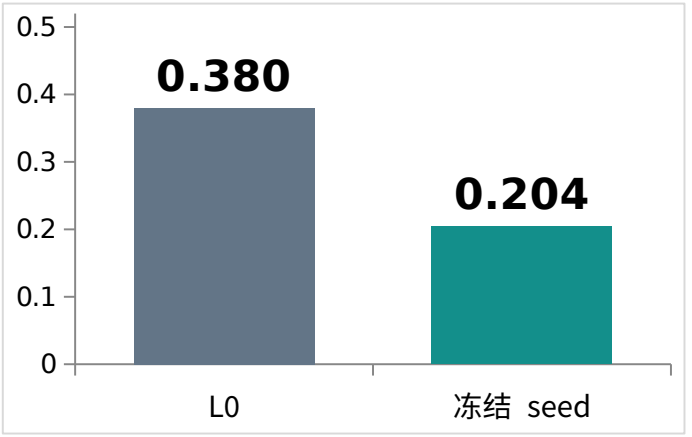
+16 题；仍需 339 才过门槛

正式有效质量 Q



+3.2 个百分点 / +4.968944%

平均无效 loop



下降 46.315789%

配对： 78 题改善 / 62 题退步 / 360 题不变；净增 16 题， strict 与 Q 门槛仍未通过。

证据： AppWorld comparison.json / L0 result.json ； 500 条摘要复算

完整指标表：冻结 seed 与当前搜索节点分开列

父策略是当前树 Node0；历史标签“71”不是当前树的 Node71。

同题 500 指标	L0	父策略：冻结 seed	当前： Node30
执行 / 有效评分	500 / 500	500 / 500	暂无新 500 结果
严格通过 / 正式 Q	322 / 0.644	338 / 0.676	暂无
平均无效 loop	0.380	0.204	暂无
时延（秒）	暂无完整统计	172.43 （500 题）	暂无
token / 模型调用	暂无完整统计	172,923.98 / 25.72 （497 题）	暂无
L1 / L2 / L3 应用	0 / 0 / 0	595 / 0 / 4	暂无同 500 指标

局部 32 题、完整 500 题与不同冻结版本不能混成一张“进化提升”成绩。

证据： comparison.json · result.json

30 轮搜索：尚未产生新的 accepted 节点

Node26 与 Node28 分别与父 Node0 在各自同题 TRAIN32 上比较；两组 32 题不同。

30 个新节点的产出

新 accepted： 0
反思调用： 395
error13 / duplicate5
不可触发 4 / interrupted3
不确定 2 / 未观测变更 2
训练拒绝 1

Node26： 全池净增 2

父 Node0 → 子 26，同 32 题
全池 strict： 22 → 24
实际影响 8 题： 6 → 6
新增关键违规 1，节点被拒
全池改善不等于变更收益

Node28： 新控制未介入

父 Node0 → 子 28，另一 32 题
全池 strict： 25 → 26
新增 L3 实际应用： 0
既有 L1 应用： 32 次
终态 unobserved_changes

TRAIN32 不是 val 或 500；候选合法、实际介入和同题收益需要分别核验。

证据： tree.json · WORK_STATUS.md:1-7

业务实验显示：成绩选择可能掩盖整体退步

业务与 AppWorld 独立展示；下表不是跨基准比较。

同范围业务对照	L0	候选	结果边界
已选 300： Q / strict	0.469022 / 113	0.557833 / 145	按已测成绩选子集
已选 300：无效 loop	3.07333	1.97333	开发选择结果
full400： Q / strict	0.528392 / 177	0.511717 / 168	完整 400 范围退步
full400：无效 loop	2.870	2.955	重复无效迭代增加
最终 500 范围	业务 300 + 回放 200	all_goals_met=true	非独立留出

下一轮必须先冻结评测范围，再看候选成绩；不能按成绩反向选题。

证据：业务 seed004 comparison300.json 的 L0/candidate/full400/limitations

目前的主要问题集中在四个证据缺口

将已确认的事实、静态限制和待检验假设分开处理。

介入与收益未闭合

L2=0 、 L3=4 ； 生成规则和实际改变行为脱节

泛化评测不独立

开发反馈污染；业务子集存在成绩选择偏差

稳定性与成本不足

0 新 accepted ； 基线与额外尝试费用不完整

运行与来源边界

v1/v2 接线差异；原报告缺失；回执≠落盘

优先补可验证关键链路，再扩候选空间或增加搜索预算。

证据： comparison.json · tree.json

下一步研究问题：触发、控制与泛化如何闭合?

以下是依据当前限制提出的研究建议，尚未实现或验证。

RQ1： 触发准确性

观察 + 任务阶段 + scope，能否减少误注入和漏注入?

RQ2： 行为控制价值

实际 L2/L3 介入，能否减少无效 loop 并保持成功?

RQ3： 跨任务泛化

冻结策略能否改善未参与开发的任务族?

推荐主线：证据约束的条件触发与行为控制；把 GEPA 作为候选优化基础。

方向一：让经验在正确阶段触发，并留下可核验证据

保留来源和授权；将轻量条件编译与词面基线进行比较。

01

训练事实

错误与恢复

正 / 负样本

02

后台编译

条件 / 阶段

有限结构化规则

03

在线匹配

分支真实状态

有界低开销

04

应用证据

query → 请求

动作差分

05

独立验收

冻结后评测

成功 / loop / 误触发

把“是否相关”推进为“何时适用”，并单独测量触发准确性与任务收益。

方向二：用消融和配对实验检验真实收益

模型、宿主、任务、预算与裁判保持一致；评测不向记忆回写。

组别	改变的因素	要回答的问题
A： L0	不启用策略增强	原始成功率与成本
B： 固定经验	同一批准经验快照	经验内容是否有用
C： 条件 L1	仅改变触发机制	阶段条件是否优于词面基线
D： L1 + L2/L3	受控动作或 loop 策略	控制对成功与 loop 的增量贡献
消融 / 重复	逐层关闭；多随机重复	归属、稳定性、退化与总成本

先验证介入，再验证收益；用未触碰确认集检验泛化。

建议按证据闭合顺序推进，而非继续堆搜索轮数

阶段与耗时为规划建议；以验收条件为准，不作完成承诺。

建议阶段	主要产物	进入下一步的条件
1： 证据准备	可迁移原报告 / 版本 / 配置 / 成本包	来源可重验；范围与接线明确
2： 小范围机制	条件触发与回执验证；错误分类	真实介入，误触发和退化可量化
3： 开发消融	等预算对照与多次重复	开发集稳定收益，策略冻结
4： 一次确认	未触碰确认集结果；区间与总成本	完成独立验收，保留失败和未达标

优先级：可重验证据 → 条件触发 → 层级消融 → 独立确认。

请导师帮助确定三个取舍

带着清楚的系统基础与证据边界，讨论一个可收敛的研究目标。

研究主线

条件触发 + 行为控制
或后台搜索效率?

任务与边界

AppWorld 主评测；业务机制诊断
确认集如何冻结?

预算与验收

允许的控制范围、重复次数
总成本与阶段退出条件?

拟议定位：基于真实执行证据的、可验证的 Agent 行为自进化。

源码阅读路线：先运行链，再学习链

按问题导航；路径与符号以当前提交为准。

要掌握的问题	优先阅读
请求与批次	chat_rest.py → rpc_handler.cpp → session_router.cpp → agent.cpp
模型与工具	llm_call.py → coordinator_decide.py → skill_executor.py
采集与持久化	local_runtime.cpp / integration_service.cpp
学习与运行策略	evolution_pipeline.cpp → memory → policy_runtime.cpp
后台选优与验收	agent_evaluation.cpp → gepa_search.cpp → gepa_strategy.cpp
可复现实验	experiments/appworld/README.md → reproduce.sh → manifest

日常构建 ./scripts/build.sh dev；组件另行构建；测试范围不能混算。

接入范围： v1 、 v2 、配置与入口必须分开核验

默认模板 v2 ，与当前已有直接演化打点的 v1 路径存在差异。

当前直接接线

v1 ： 模型 / 工具 / 派发 / loop

默认模板

脚本缺省 v2 ； wrapper 环境缺省 v1 ，需核验

启用条件

实际环境值、 EVOLUTION_POINT_CONFIG 、服务 / 身份

评测入口

专用 runner 显式 v1 ； Bridge 评测有专门开关

报告“组件已集成”时，同时说明宿主版本、配置与真实应用证据。

证据： llm_call.py:89 · skill_executor.py:83

持久化与恢复：接受、落盘与业务续跑不同

下面是静态源码确认的能力边界，未做本轮故障注入。

位置	当前能确认	不能据此宣称
原生采集	内存接受；初始 / 最终快照落盘	每个中间事件都可恢复
HTTP buffered	队列接受； status / flush 确认落盘	run.end 成功必定已持久化
启动恢复	已落盘不完整运行 abort / quarantine	故障后从原工具动作自动续跑
后台作业	恢复学习 / 评测检查点	复原未落盘的全部业务事件
归档	移入 archive ；可历史读取	自动释放磁盘或具备总字节配额

可靠性研究前先定义允许丢失窗口、恢复责任与磁盘保留策略。

证据： local_runtime.cpp:671-738 • integration_service.cpp:669-695,844,1340,2685,2743,2804

状态字典：同一个“完成”不能覆盖整条链路

这些状态需要各自的证据，不能依次推定。

状态	回答的问题
completed / persisted	执行是否终态 / 采集是否已落盘
evaluated / approved	评分是否完整 / 经验是否获得应用资格
published / delivered	哪个产物被交付？合格还是最佳可用？
loaded_version / advice.applied	加载了哪个版本 / 实际使用了何种增强
passed / goal_passed	任务严格通过 / 实验门槛是否达成
client.delivery	服务端观察； client_acknowledged=false

实现、启用、应用、收益和泛化分别建立证据。

证据包：现有摘要可复算，原生来源仍需补齐

当前本机证据与原运行产物分开描述，避免把旧路径当现存文件。

本机已保留

策略 / memory / tree / 两边 500 逐题摘要

本次可复算

strict 、 Q 、 loop 、 L1-L3 ； 候选部分资源

本机缺失

6 份候选 native report + L0 原报告等

下一步归档

环境 / 版本 / 脱敏配置 / 官方 IO / 全尝试成本

摘要自洽是必要条件；可审查原始事实和可重跑复现还需原生来源。

官方完成率与仓库严格验收分开报告

仓库的正式 strict/Q 加入了额外严格验收，不直接等于官方 TGC 。

正式严格验收

322 → 338 ； 确定性与模型严格条件共同满足

官方任务完成

323 → 339 ； 官方状态字段，按独立口径报告

正式有效 Q

本批单目标 Q 为 0/1 ； 均值等于正式 strict 率

辅助检查比例

official_quality 为部分检查比例；不替代严格通过

主图 64.4% → 67.6% 是仓库正式口径；公开汇报须保留这一说明。

可复现入口与本次核查范围

命令作为入口说明；本次没有执行模型实验、服务启动或构建回归。

动作	用途	当前报告边界
--fresh	真实训练 → 学习 → 搜索 → 对照 → 发布	会执行模型；本次未运行
--resume	按冻结身份恢复原作业	不是新树或改旧成绩
--plan / --status	只读阶段安排与状态	状态字段仍需原产物核验
--deliver-best-available	导出现有完整已评分策略	不代表目标达标或 GEPA 完成
本轮核查	静态源码、摘要复算、来源与文稿渲染	未跑构建、回归或真实模型验收

可复现脚本存在、运行成功、成绩稳定复现是三个不同结论。

证据： README.md · reproduce.sh

导师可能追问的五个问题

回答时先给结论，再给证据边界。

问题	可据当前证据回答
是否训练了模型?	当前不更新权重；演化经验、动作与 loop 策略。
自进化已经成功吗?	开发范围改善；质量门槛未达；独立泛化待验证。
L2/L3 贡献有多大?	L2=0 、 L3=4 ；尚需真实触发、配对消融和重复实验。
GEPA30 轮有效吗?	当前 0 新 accepted ；保留真实状态，不把搜索次数当收益。
下一步贡献是什么?	条件触发与可验证控制；独立验收稳定收益及完整成本。

已实现机制可以讲清楚；尚未证明的收益作为下一步研究问题。